Εργασία 1 - Επεξεργασία Φυσικής Γλώσσας (N-grams)

Φαίδων Γραμματικόπουλος

Μάθημα: Επεξεργασία Φυσικής Γλώσσας
Διδάσκων: Ε. Σταματάτος

MSc in Artificial Intelligence
University of Piraeus & NCSR "DEMOKRITOS", Greece

Απρίλιος 2026

Εισαγωγή

Στην παρούσα εργασία μελετώνται δύο θεμελιώδη θέματα της Επεξεργασίας Φυσικής Γλώσσας (NLP):

- Ο τεμαχισμός κειμένου σε tokens (tokenization)
- Τα στατιστικά γλωσσικά μοντέλα των n-grams

Στο **Μέρος Α** εφαρμόζονται τρεις μέθοδοι tokenization NLTK, spaCy και BERT σε corpus ειδήσεων από την εφημερίδα Wall Street Journal. Για κάθε μέθοδο υπολογίζονται βασικά στατιστικά (tokens, types, TTR, hapax legomena/dislegomena), συγκρίνονται οι παραγόμενες ακολουθίες tokens σε επίπεδο πρότασης, και αναλύεται η συμφωνία της κατανομής συχνοτήτων με τον Νόμο του Zipf.

Στο **Μέρος Β** κατασκευάζονται γλωσσικά μοντέλα bigram και trigram με εξομάλυνση add-k (smoothing), χρησιμοποιώντας το Penn Treebank corpus του NLTK. Αξιολογείται η επίδοση (perplexity) κάθε μοντέλου υπό τρεις μορφές προεπεξεργασίας αρχικό κείμενο, πεζά γράμματα, και αφαίρεση ψηφίων και τέλος παράγονται νέες προτάσεις μέσω στοχαστικής δειγματοληψίας.

Ο κώδικας υλοποιήθηκε σε Python και είναι διαθέσιμος ως αυτόνομα scripts:

- ***scripts/part_a.py***
- ***scripts/part_b.py***

αλλά και ως ενοποιημένο Jupyter Notebook (***assignment_1.ipynb***) στο ανοικτό αποθετήριο στο github : [https://github.com/Fgram-devAI/nlp-ncsr-task1].

Κεφάλαιο 1

Μέρος Α: Tokens, Types, Νόμος του Zipf

1.1 Α.1 - Πίνακας Στατιστικών

Εφαρμόσαμε τρεις μεθόδους tokenization στο corpus WSJ (**wsj_untokenized.txt**): το **nltk.word_tokenize()** που εκτελεί tokenization σε επίπεδο λέξης με κανόνες για σημεία στίξης και συντμήσεις, το μοντέλο **en_core_web_sm** του spaCy που χρησιμοποιεί στατιστικό tokenizer, και τον **BertTokenizer** (**bert-base-cased**) που παράγει subword tokens βάσει του αλγορίθμου WordPiece. Ο παρακάτω πίνακας συνοψίζει τα αποτελέσματα:

	NLTK	**spaCy**	**BERT**
#tokens	93.530	95.925	112.325
#types	12.000	11.522	10.266
TTR	0,1283	0,1201	0,0914
Hapax legomena	6.254	5.788	3.851
Hapax dislegomena	1.830	1.795	1.724

Πίνακας 1.1: Στατιστικά tokenization για το corpus WSJ.

Σχόλιο:

- **Μεγαλύτερο λεξιλόγιο**: Το NLTK παράγει τα περισσότερα types (12.000) διότι διατηρεί τις σύνθετες λέξεις με παύλα ως ενιαία tokens (π.χ. **garden-variety**), δημιουργώντας περισσότερες μοναδικές μορφές. Το BERT παράγει τα λιγότερα types (10.266) επειδή το λεξιλόγιό του είναι σταθερό (30.522 εγγραφές) και αποσυνθέτει τις σπάνιες λέξεις σε γνωστά subword τμήματα αντί να δημιουργεί νέα types.
- **TTR**: Το BERT έχει το χαμηλότερο TTR (0,0914) διότι το subword tokenization αυξάνει σημαντικά τον αριθμό των tokens (112.325 έναντι ∼94.000 για τις μεθόδους σε επίπεδο λέξης), ενώ ο αριθμός των types παραμένει χαμηλός. Το NLTK έχει το υψηλότερο TTR (0,1283), υποδεικνύοντας μεγαλύτερη λεξιλογική ποικιλία. Όλες οι τιμές TTR είναι χαμηλές ($< 0,13$), κάτι αναμενόμενο για μεγάλο corpus με πολλές επαναλαμβανόμενες λειτουργικές λέξεις.

- **Hapax legomena/dislegomena και Νόμος του Zipf**: Ο νόμος του Zipf προβλέπει ότι μεγάλο ποσοστό των types εμφανίζεται πολύ σπάνια. Αυτό επιβεβαιώνεται: για το NLTK, τα hapax legomena αντιπροσωπεύουν $6.254/12.000 = 52,1\%$ όλων των types, που ισοδυναμεί με το ότι περισσότερο από το μισό λεξιλόγιο εμφανίζεται μόνο μία φορά. Αυτό είναι συνεπές με την πρόβλεψη του Zipf ότι η κατανομή συχνοτήτων έχει μακριά ουρά. Το BERT έχει λιγότερα hapax legomena (37,5% των types) επειδή η subword αποσύνθεση μειώνει τον αριθμό των πραγματικά σπάνιων tokens.

1.2 A.2 - Σύγκριση Tokens σε Επίπεδο Πρότασης

Επιλεγμένη πρόταση (19 λέξεις):

> ``*The scammers themselves were garden-variety low lifes, conspicuous consumers who wanted big houses, Mercedes cars, beautiful women, expensive clothes.*''

Μέθοδος	**#Tokens**	**Βασικές διαφορές**
NLTK	24	Διατηρεί το **garden-variety** ως ένα token
spaCy	26	Χωρίζει **garden-variety** → **garden**, **-**, **variety**
BERT	29	Subword: **scammers** → **s**, **##cam**, **##mers**; **lifes** → **life**, **##s**

Πίνακας 1.2: Σύγκριση tokens για την επιλεγμένη πρόταση.

Το NLTK διατηρεί σύνθετες λέξεις. Το spaCy χωρίζει στις παύλες. Το BERT αποσυνθέτει τις σπάνιες λέξεις σε subword μονάδες (πρόθεμα **##** υποδεικνύει συνέχεια).

1.3 A.3 - Συχνότερα Types που Καλύπτουν το 30% των Tokens

- NLTK: 16 types καλύπτουν το 30% των tokens
- spaCy: 16 types καλύπτουν το 30% των tokens
- BERT: 14 types καλύπτουν το 30% των tokens
- **11 types είναι κοινά και στις 3 μεθόδους**: **, . The a and for in of that the to**

Αυτό επιβεβαιώνει ότι ένα ελάχιστο κλάσμα των types ($< 0,15\%$ του λεξιλογίου) αντιστοιχεί σχεδόν στο ένα τρίτο όλων των tokens, πράγμα που αποτελεί άμεση συνέπεια του νόμου του Zipf. Τα κοινά types είναι λειτουργικές λέξεις και σημεία στίξης που κυριαρχούν σε κάθε αγγλικό corpus.

1.4 A.4 - Νόμος του Zipf

Η καλύτερη τιμή της σταθεράς είναι $A = 0,1$, η οποία προσδιορίστηκε ελαχιστοποιώντας το άθροισμα τετραγωνικών σφαλμάτων μεταξύ παρατηρούμενων και προβλεπόμενων πιθανοτήτων για τις υποψήφιες τιμές $\{0,1;\ 0,2;\ \ldots;\ 1,0\}$.

Ο νόμος του Zipf δηλώνει:

$$P(r) = \frac{A}{r}$$

όπου r είναι η θέση ενός type στη φθίνουσα κατάταξη συχνότητας.

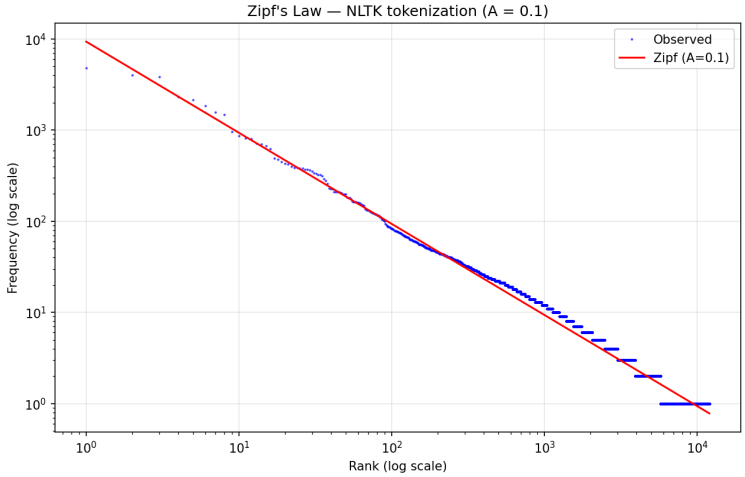

Σχήμα 1.1: Διάγραμμα log-log παρατηρούμενων συχνοτήτων (μπλε) έναντι πρόβλεψης του νόμου Zipf με $A = 0,1$ (κόκκινο). Η προσαρμογή είναι καλή για τα υψηλής συχνότητας types αλλά αποκλίνει στην ουρά, κάτι τυπικό καθότι ο νόμος του Zipf αποτελεί προσέγγιση.

Μέρος Β: Γλωσσικά Μοντέλα N-gram

1.5 Β.1 - Πίνακας Perplexity

Γλωσσικό μοντέλο	Αρχικό κείμενο	Lowercase	Αφηρημένα ψηφία
Bigrams ($k = 1$)	383,66	384,11	351,55
Bigrams ($k = 0,01$)	137,83	143,81	125,40
Trigrams ($k = 1$)	1351,97	1355,75	1250,89
Trigrams ($k = 0,01$)	429,37	443,44	383,52

Πίνακας 1.3: Perplexity γλωσσικών μοντέλων n-gram με add-k smoothing.

Σχολιασμός:

- **Bigrams έναντι trigrams**: Τα bigrams επιτυγχάνουν σταθερά χαμηλότερο perplexity σε όλες τις ρυθμίσεις. Αυτό οφείλεται στο μικρό μέγεθος του corpus εκπαίδευσης ($\sim$3.500 προτάσεις), με αποτέλεσμα τα περισσότερα trigrams στο σύνολο αξιολόγησης να μην έχουν παρατηρηθεί κατά την εκπαίδευση. Το add-k smoothing κατανέμει την πιθανότητα σε $|V|^3$ πιθανά trigrams ($|V|^2$ για bigrams), κάνοντας την κατανομή πολύ ομοιόμορφη. Με μεγαλύτερο corpus, τα trigrams αναμένεται να υπερτερούν.

- **Τιμή k**: Η τιμή $k = 0,01$ είναι σημαντικά καλύτερη από $k = 1$ σε όλες τις περιπτώσεις. Η εξομάλυνση Laplace ($k = 1$) εκχωρεί υπερβολική πιθανότητα στα μη παρατηρημένα n-grams, διαταράσσοντας την κατανομή και μειώνοντας τη βεβαιότητα στα παρατηρημένα πρότυπα. Μικρότερο k διατηρεί πιστότερα την κατανομή.

- **Lowercase**: Η μετατροπή σε πεζά αυξάνει ελαφρώς το perplexity (π.χ. 137,83 $\rightarrow$ 143,81 για bigrams, $k = 0,01$). Μειώνει το μέγεθος του λεξιλογίου, συγχωνεύει προηγουμένως διακριτά συμφραζόμενα (π.χ. ``The" στην αρχή πρότασης έναντι ``the" στο εσωτερικό), εισάγοντας όμως ασάφεια που βλάπτει την πρόβλεψη.

- **Αφηρημένα ψηφία**: Η αντικατάσταση ψηφίων με **#** μειώνει σταθερά το perplexity (καλύτερο αποτέλεσμα: 125,40). Αυτό συμβαίνει διότι πολλοί διαφορετικοί αριθμοί συμπτύσσονται σε ένα μοτίβο (``####"), μειώνοντας σημαντικά την αραιότητα του λεξιλογίου και επιτρέποντας στο μοντέλο να προβλέπει καλύτερα αριθμητικά συμφραζόμενα.

1.6 B.2 - Παραγωγή Προτάσεων

Για κάθε μοντέλο n-gram (εκπαιδευμένο στο αρχικό κείμενο χωρίς προεπεξεργασία, $k = 0,01$), παράγονται 3 προτάσεις. Κάθε πρόταση ξεκινά με **<BOS>** και επιλεγμένες αρχικές λέξεις, και τερματίζει στο **<EOS>**. Η επόμενη λέξη επιλέγεται τυχαία αναλογικά με την πιθανότητα του n-gram.

Μοντέλο Bigram:

1. The reason million *U* .
2. Mr. Cannell revive private Volume features compete mechanical prison Australian 1999 regulation determined ran 'm economist met Mr. hearing sophisticated , " caused trouble analysts Smith anyone ...
3. In the two Candela Carnival said 0 it bring individuals law in January by a sales withdraw town existing debts Stag 's .

Μοντέλο Trigram:

1. The reason passage compromise States estimates claims protecting acquisition disgorge hazards substance encourage VOA poor intellectual-property Sherwood successor ...
2. Mr. Coleman seemed preparation Southeast editorial curriculum line purchased Carlos 1988 right contract precisely 'd crime opinion ...
3. In the trillion 767 Brazil rider particularly margins adjusted in included hard If contemporary certainly options worth tree ...

Σχολιασμός:

- Το μοντέλο **bigram** παράγει προτάσεις με τοπική συνοχή (διαδοχικά ζεύγη λέξεων φαίνονται λογικά), αλλά χωρίς καθολική δομή ή νόημα. Η πρώτη πρόταση είναι σύντομη και τερματίζει γρήγορα, ενώ η δεύτερη συνεχίζει μέχρι το μέγιστο όριο χωρίς να βρει **<EOS>**, υποδεικνύοντας ότι το μοντέλο δυσκολεύεται να ``κλείσει" μια πρόταση.
- Το μοντέλο **trigram** παράγει ακόμα λιγότερο συνεκτικές προτάσεις, παρά το μεγαλύτερο μήκος συμφραζομένων. Αυτό οφείλεται στην αραιότητα δεδομένων: τα περισσότερα trigrams δεν παρατηρήθηκαν κατά την εκπαίδευση, οπότε η εξομάλυνση κατανέμει σχεδόν ομοιόμορφα την πιθανότητα και η επιλογή γίνεται ουσιαστικά τυχαία.
- Συνολικά, η ποιότητα των παραγόμενων προτάσεων είναι χαμηλή και στα δύο μοντέλα, κάτι αναμενόμενο για n-gram μοντέλα εκπαιδευμένα σε μικρό corpus. Τα bigrams υπερτερούν ελαφρώς, καθώς τουλάχιστον παράγουν πιθανά ζεύγη λέξεων.